Recherche exhaustive — Datasets & Études pour la prévision énergétique industrielle

Document de référence pour le pipeline de forecasting 30 ans (type OCP)

SECTION 1 — DATASETS

1.1 Datasets énergétiques globaux (long terme, multi-pays)

★★★ Our World in Data — Energy Dataset

- **Description** : Dataset complet sur la consommation énergétique mondiale, couvrant plus de 200 pays depuis 1900. Inclut énergie primaire, mix énergétique, mix électrique, émissions CO2, consommation par habitant, et indicateurs GDP/population.
- **Type** : Global / Multi-sectoriel
- **Format** : CSV, XLSX, JSON
- **Colonnes clés** : primary_energy_consumption, electricity_generation, fossil_fuel_consumption, renewables_share, gdp, population
- **Profondeur** : ~120 ans de données annuelles
- **Lien GitHub** : https://github.com/owid/energy-data
- **Téléchargement direct CSV** : https://raw.githubusercontent.com/owid/energy-data/master/owid-energy-data.csv
- **Codebook** : https://github.com/owid/energy-data/blob/master/owid-energy-codebook.csv
- **Pertinence pour LSTM 30 ans** : ★★★★★ — Meilleur dataset pour tendances long terme + scénarios macro. Filtrer sur Morocco pour données OCP-contextuelles.

★★★ IEA World Energy Outlook 2025 Free Dataset

- **Description** : Données agrégées mondiales pour 3 scénarios (CPS, STEPS, NZE) avec projections jusqu'en 2050 + historique depuis 2010. Inclut offre d'énergie, consommation finale, génération électrique, capacités, émissions CO2.
- **Type** : Global / Prospectif
- **Format** : Excel (téléchargement gratuit après inscription)
- **Lien** : https://www.iea.org/data-and-statistics/data-product/world-energy-outlook-2025-free-dataset
- **Licence** : CC BY-NC-SA 4.0

- **Pertinence pour LSTM 30 ans** : ★★★★★ — Indispensable pour calibrer les scénarios prospectifs (STEPS/NZE). Sert de référence pour les trajectoires exogènes.

★★★ World Bank — Energy Indicators (Maroc)

- **Description** : Indicateurs énergie par pays via l'API World Bank Open Data. Pour le Maroc : consommation électrique par habitant, part renouvelables, importations nettes, accès à l'électricité, émissions.
- **Type** : National / Annuel
- **Format** : CSV via API, Excel
- **Liens directs (Maroc)** :
  - Consommation électrique/habitant : https://data.worldbank.org/indicator/EG.USE.ELEC.KH.PC?locations=MA
  - Part renouvelables : https://data.worldbank.org/indicator/EG.FEC.RNEW.ZS?locations=MA
  - Importations nettes : https://data.worldbank.org/indicator/EG.IMP.CONS.ZS?locations=MA
  - Accès électricité : https://data.worldbank.org/indicator/EG.ELC.ACCS.ZS?locations=MA
- **API bulk download** : https://data.worldbank.org/indicator?tab=all (filtrer par EG.*)
- **Pertinence** : ★★★★☆ — Contexte macro-économique marocain essentiel pour les variables exogènes.

★★ Kaggle — World Energy Consumption

- **Description** : Miroir du dataset OWID enrichi, avec données BP Statistical Review + EIA. Couvre consommation, production, mix énergétique par pays et par année.
- **Type** : Global / Annuel
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/pralabhpoudel/world-energy-consumption
- **Pertinence** : ★★★☆☆ — Redondant avec OWID mais utile pour un accès rapide Kaggle avec notebooks prêts.

★★ Kaggle — UN International Energy Statistics

- **Description** : Statistiques énergétiques de l'ONU couvrant production, commerce, transformation et consommation d'énergie par pays depuis 1990.
- **Type** : Global / Multi-sectoriel
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/unitednations/international-energy-statistics

- **Pertinence** : ★★★★☆ — Excellente profondeur historique, données par secteur industriel.

1.2 Datasets séries temporelles haute résolution (entraînement DL)

★★★ PJM Hourly Energy Consumption

- **Description** : Consommation électrique horaire du réseau PJM (Eastern USA), couvrant plusieurs régions. Données de 2002 à 2018. Plus de 140 000 observations par région.
- **Type** : Réseau électrique / Horaire
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/robikscube/hourly-energy-consumption
- **Colonnes** : datetime, energy_consumption_MW (par région)
- **Pertinence pour LSTM** : ★★★★★ — Dataset de référence pour entraîner et valider les architectures LSTM/TFT sur séries temporelles longues. 16+ ans de données horaires.

★★★ Open Power System Data (OPSD) — Time Series

- **Description** : Données horaires (15min/30min/60min) de consommation électrique, génération éolienne/solaire, et prix spot pour 36 pays européens. Scripts de traitement open-source.
- **Type** : Réseau électrique européen / Horaire
- **Format** : CSV, SQLite, Excel
- **Lien** : https://data.open-power-system-data.org/time_series/
- **GitHub** : https://github.com/Open-Power-System-Data/time_series
- **Pertinence pour LSTM** : ★★★★★ — Données multi-pays, multi-résolution, avec documentation exemplaire. Idéal pour benchmarking et transfer learning.

★★ UCI — Individual Household Electric Power Consumption

- **Description** : Mesures minute par minute d'une maison en France sur 4 ans (2006-2010). ~2 millions de lignes. Inclut puissance active/réactive, voltage, sous-compteurs.
- **Type** : Résidentiel / Minute
- **Format** : CSV (via Kaggle)
- **Lien** : https://www.kaggle.com/datasets/uciml/electric-power-consumption-data-set
- **Pertinence** : ★★★☆☆ — Bon pour prototypage rapide de modèles LSTM, mais échelle résidentielle (pas industrielle).

1.3 Datasets industriels (usines, capteurs, manufacturing)

★★★ Steel Industry Energy Consumption Dataset

- **Description** : Consommation énergétique réelle d'une usine sidérurgique en Corée du Sud. 35 000+ observations à résolution de 15 minutes. Inclut puissance réactive, facteur de puissance, CO2, charge type, jour de semaine.
- **Type** : Industriel / 15 minutes
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/csafrit2/steel-industry-energy-consumption
- **Colonnes clés** : Usage_kWh, Lagging_Current_Reactive.Power_kVarh, CO2, Load_Type, WeekStatus, Day_of_week
- **Pertinence pour LSTM** : ★★★★★ — Le plus proche d'un dataset OCP accessible publiquement. Données réelles d'usine avec saisonnalité et variables opérationnelles.

★★ UNICON Energy Consumption Dataset

- **Description** : Données de consommation énergétique multi-bâtiments universitaires et industriels avec capteurs IoT.
- **Type** : Mixte (bâtiment + industriel)
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/cdaclab/unicon
- **Pertinence** : ★★★☆☆ — Bonne source pour prototypage multivarié.

★★ Smart Manufacturing Process Data

- **Description** : Données de processus de fabrication intelligente incluant capteurs de température, pression, vibrations et énergie.
- **Type** : Manufacturing / Capteurs
- **Format** : CSV
- **Lien** : https://www.kaggle.com/datasets/programmer3/smart-manufacturing-process-data
- **Pertinence** : ★★★☆☆ — Utile pour la composante maintenance/arrêts du modèle.

★★ Awesome Industrial Datasets (Collection GitHub)

- **Description** : Collection curatée de plus de 100 datasets industriels publics, incluant énergie, maintenance prédictive, capteurs, manufacturing.
- **Type** : Méta-collection
- **Format** : Liens vers CSV/autres
- **Liens** :

    - https://github.com/jonathanwvd/awesome-industrial-datasets
    - https://github.com/makinarocks/awesome-industrial-machine-datasets
- **Pertinence** : ★★★★☆ — Point d'entrée essentiel pour trouver des datasets complémentaires spécifiques.

1.4 Datasets spécifiques phosphate/OCP (variables exogènes)

★★★ USGS — Phosphate Rock Historical Statistics (Data Series 140)

- **Description** : Statistiques historiques complètes sur le phosphate rock : production mondiale par pays, prix, réserves, imports/exports USA. Données depuis les années 1900.
- **Type** : Minéral / Annuel
- **Format** : XLSX
- **Lien téléchargement** : https://www.usgs.gov/media/files/phosphate-rock-historical-statistics-data-series-140
- **Page principale** : https://www.usgs.gov/centers/national-minerals-information-center/phosphate-rock-statistics-and-information
- **Données MCS 2025** : https://data.usgs.gov/datacatalog/data/USGS:679801b8d34ea8c18376e20c
- **Pertinence** : ★★★★★ — Indispensable pour les variables exogènes liées à la production phosphatière. Production Maroc incluse.

★★ Our World in Data — CO2 & GHG Emissions

- **Description** : Émissions CO2 et GES par pays depuis 1750. Inclut émissions par secteur, par combustible, intensité carbone, et indicateurs économiques.
- **Type** : Global / Annuel
- **Format** : CSV, XLSX, JSON
- **Lien GitHub** : https://github.com/owid/co2-data
- **Téléchargement direct** : https://raw.githubusercontent.com/owid/co2-data/master/owid-co2-data.csv
- **Pertinence** : ★★★★☆ — Variable exogène pour modéliser l'impact des réglementations carbone sur la demande énergétique.

★★ World Bank — Commodity Price Data (Pink Sheet)

- **Description** : Prix mensuels des matières premières mondiales depuis 1960 : énergie (pétrole, gaz, charbon), engrais (DAP, phosphate rock, urée), métaux, agriculture.
- **Type** : Prix / Mensuel

- **Format** : Excel
- **Lien** : https://www.worldbank.org/en/research/commodity-markets
- **Pertinence** : ★★★★★ — Prix du phosphate rock, DAP, gaz naturel, pétrole — toutes les variables exogènes de marché nécessaires pour OCP.

1.5 Données climatiques (variable exogène)

★★ Open-Meteo Historical Weather API

- **Description** : API gratuite fournissant données météo historiques horaires pour n'importe quel point du globe. Température, humidité, vent, irradiance solaire, précipitations.
- **Type** : Météo / Horaire
- **Format** : JSON/CSV via API
- **Lien** : https://open-meteo.com/en/docs/historical-weather-api
- **Pertinence** : ★★★★☆ — Données météo pour les sites OCP (Khouribga, Safi, Jorf Lasfar). Gratuit et sans clé API.

SECTION 2 — ÉTUDES SCIENTIFIQUES & ARTICLES

2.1 Articles fondateurs

Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting

- **Auteurs** : Bryan Lim, Sercan Ö. Arık, Nicolas Loeff, Tomas Pfister (Google Research)
- **Année** : 2021 (ICML 2021)
- **Résumé** : Présente l'architecture TFT qui combine Variable Selection Networks, LSTM encoder-decoder, et multi-head attention interprétable. Le modèle produit des prédictions par quantiles et permet d'identifier l'importance relative des features et les patterns d'attention temporelle.
- **Méthode** : Temporal Fusion Transformer (TFT)
- **Lien** : https://arxiv.org/abs/1912.09363
- **Impact** : Article fondateur — l'architecture TFT est devenue la référence pour le forecasting multivarié industriel.

Long Short-Term Memory (original paper)

- **Auteurs** : Sepp Hochreiter, Jürgen Schmidhuber

- **Année** : 1997
- **Résumé** : Article fondateur introduisant l'architecture LSTM avec ses portes d'entrée, de sortie et d'oubli, résolvant le problème du gradient évanescent dans les RNN.
- **Méthode** : LSTM
- **Lien** : https://doi.org/10.1162/neco.1997.9.8.1735

2.2 Articles récents sur le forecasting énergétique (2024-2025)

Multivariate LSTM-Based Forecasting for Renewable Energy: Enhancing Climate Change Mitigation

- **Année** : Janvier 2025
- **Résumé** : Développe un réseau M-LSTM multivarié pour prévoir la génération d'énergies renouvelables en utilisant des données historiques réelles de la province d'Alberta. Montre que M-LSTM surpasse les baselines en termes de NMAE et réduit les émissions CO2 du système électrique.
- **Méthode** : Multivariate LSTM
- **Lien** : https://arxiv.org/abs/2601.10961

Short-Term Electricity-Load Forecasting by Deep Learning: A Comprehensive Survey

- **Année** : 2025 (Engineering Applications of Artificial Intelligence)
- **Résumé** : Survey complet sur 10 ans de deep learning pour le load forecasting. Couvre CNN, LSTM, GRU, Transformer, modèles hybrides CNN-LSTM, méthodes probabilistes, et stratégies de feature engineering. Analyse plus de 200 publications.
- **Méthode** : Survey (LSTM, CNN, Transformer, hybrides)
- **Lien** : https://arxiv.org/abs/2408.16202

An Approach to Predicting Energy Demand Within Automobile Production Using the Temporal Fusion Transformer Model

- **Année** : Décembre 2024 (Energies, MDPI)
- **Résumé** : Applique le TFT à la prévision hebdomadaire de la demande d'électricité, chaleur et gaz naturel d'un site de production automobile. Obtient un MAPE de 13% pour l'électricité. Compare les approches rolling day-ahead vs prédiction directe.
- **Méthode** : TFT
- **Lien** : https://www.mdpi.com/1996-1073/18/1/2

An Optimized System for Predicting Energy Usage in Smart Grids Using Temporal Fusion Transformer and Aquila Optimizer

- **Année** : Février 2025 (Frontiers in AI)
- **Résumé** : Combine TFT avec l'optimiseur Aquila pour l'optimisation des hyperparamètres. Le modèle AO-TFT surpasse LSTM et CNN-BiLSTM en accuracy et temps de calcul pour la prédiction de consommation dans les smart grids.
- **Méthode** : TFT + méta-heuristique (Aquila Optimizer)
- **Lien** : https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1542320/full

Enhanced Load Forecasting with GAT-LSTM: Leveraging Grid and Temporal Features

- **Année** : Février 2025 (arXiv)
- **Résumé** : Propose un modèle hybride Graph Attention Network + LSTM pour le load forecasting en modélisant simultanément les dépendances spatiales (topologie du réseau) et temporelles (patterns de consommation).
- **Méthode** : GAT-LSTM (Graph + Séquentiel)
- **Lien** : https://arxiv.org/abs/2502.08376

Load Forecasting for Households and Energy Communities: Are Deep Learning Models Worth the Effort?

- **Année** : Janvier 2025 (arXiv)
- **Résumé** : Compare LSTM, xLSTM (Extended LSTM, NeurIPS 2024), et Transformer encoder-only pour le forecasting court terme. Évalue le transfer learning entre ménages. Conclut que la complexité des modèles DL n'est pas toujours justifiée pour les petits datasets.
- **Méthode** : LSTM vs xLSTM vs Transformer
- **Lien** : https://arxiv.org/abs/2501.05000

Deep Learning-Driven Hybrid Model for Short-Term Load Forecasting and Smart Grid Information Management

- **Année** : Juin 2024 (Scientific Reports, Nature)
- **Résumé** : Propose un modèle hybride GRU + TCN (Temporal Convolutional Network) avec mécanisme d'attention pour le short-term load forecasting. L'approche capture les dépendances long terme via GRU et les patterns locaux via TCN.
- **Méthode** : GRU + TCN + Attention
- **Lien** : https://www.nature.com/articles/s41598-024-63262-x

Forecasting Energy Consumption Demand Using TFT

- **Année** : 2023 (Results in Engineering, Elsevier)
- **Résumé** : Applique le TFT à la prévision de consommation dans les smart grids avec données de compteurs intelligents. Démontre la supériorité du TFT sur les modèles classiques grâce à ses mécanismes d'attention multi-échelles.
- **Méthode** : TFT
- **Lien** : https://www.sciencedirect.com/science/article/pii/S2590123023000154

SECTION 3 — STRATÉGIE DE FUSION RECOMMANDÉE

Combinaison optimale de datasets pour un modèle LSTM/TFT long terme (30 ans)

Couche 1 : Données cible (série temporelle principale)

Dataset	Rôle	Résolution	Profondeur
PJM Hourly Energy Consumption	Entraînement DL principal	Horaire	16 ans
Steel Industry Energy Consumption	Proxy industriel	15 min	~1 an
OPSD Time Series	Benchmark multi-pays	Horaire	5-10 ans

Couche 2 : Variables exogènes long terme

Dataset	Variables	Résolution	Profondeur
OWID Energy Data	Consommation par pays, mix énergétique, GDP, population	Annuel	120+ ans
World Bank Commodity Prices	Prix phosphate, DAP, gaz, pétrole	Mensuel	60+ ans
USGS Phosphate Rock DS-140	Production mondiale phosphate par pays	Annuel	100+ ans
IEA WEO 2025	Scénarios prospectifs (STEPS, NZE) à 2050	Points clés	Proj. 25 ans

Couche 3 : Variables exogènes court/moyen terme

Dataset	Variables	Résolution
Open-Meteo Historical API	Température, humidité, vent, solaire	Horaire
World Bank Morocco Indicators	PIB, industrialisation, accès électricité	Annuel
OWID CO2 Data	Émissions, intensité carbone	Annuel

Architecture de fusion

1. Le modèle DL (LSTM/TFT) est entraîné sur les données horaires (PJM/OPSD/Steel) pour apprendre les patterns séquentiels
2. Les variables exogènes annuelles/mensuelles (OWID, USGS, World Bank) sont interpolées ou intégrées comme features statiques du TFT
3. Les scénarios IEA WEO servent de contraintes pour les trajectoires long terme dans le module Monte Carlo
4. Les données météo (Open-Meteo) enrichissent les features temporelles pour capturer les effets climatiques

Workflow recommandé

```
Phase 1 (Prototypage) :
  → PJM + Steel Industry → entraîner LSTM baseline
  → Valider architecture et hyperparamètres

Phase 2 (Enrichissement) :
  → Ajouter OWID Morocco + World Bank prices comme features exogènes
  → Passer au TFT pour sélection automatique des variables

Phase 3 (Projection 30 ans) :
  → Calibrer les scénarios sur IEA WEO 2025
  → Utiliser USGS phosphate data pour trajectoires de production
  → Monte Carlo avec cône d'incertitude croissant

Phase 4 (Production OCP) :
  → Remplacer les données publiques par les données internes OCP
  → Le pipeline et les architectures restent identiques
  → Fine-tuning sur données propriétaires
```

SECTION 4 — RÉSUMÉ DES LIENS DE TÉLÉCHARGEMENT

#	Dataset	Lien direct
1	OWID Energy (CSV)	https://raw.githubusercontent.com/owid/energy-data/master/owid-energy-data.csv
2	OWID CO2 (CSV)	https://raw.githubusercontent.com/owid/co2-data/master/owid-co2-data.csv
3	PJM Hourly Energy	https://www.kaggle.com/datasets/robikscube/hourly-energy-consumption
4	Steel Industry Energy	https://www.kaggle.com/datasets/csafrit2/steel-industry-energy-consumption
5	OPSD Time Series	https://data.open-power-system-data.org/time_series/
6	UN Energy Statistics	https://www.kaggle.com/datasets/unitednations/international-energy-statistics
7	IEA WEO 2025 Free	https://www.iea.org/data-and-statistics/data-product/world-energy-outlook-2025-free-dataset
8	USGS Phosphate DS-140	https://www.usgs.gov/media/files/phosphate-rock-historical-statistics-data-series-140
9	World Bank Morocco	https://data.worldbank.org/indicator/EG.USE.ELEC.KH.PC?locations=MA
10	Open-Meteo API	https://open-meteo.com/en/docs/historical-weather-api
11	World Bank Commodities	https://www.worldbank.org/en/research/commodity-markets
12	Smart Manufacturing	https://www.kaggle.com/datasets/programmer3/smart-manufacturing-process-data
13	Industrial Datasets Hub	https://github.com/jonathanwvd/awesome-industrial-datasets
14	World Energy (Kaggle)	https://www.kaggle.com/datasets/pralabhpoudel/world-energy-consumption

Document compilé le 7 avril 2026 — Recherche effectuée avec sources vérifiées et liens actifs.